# Université de Savoie Mont Blanc

**discipline :**

**Modélisation Mathématique et Analyse Appliquée**

Rapport de Stage

Realisé par :
MARZAK Brahim

Encadré par :
Dr. laurent VUILLON

# REMERCIEMENTS

Je tiens à remercier toutes les personnes qui ont contribué au succès de mon stage et qui m'ont aidé lors de la rédaction de ce rapport.

Tout d'abord, j'adresse mes remerciements à mes professeurs de l'Université Savoie Mont Blanc qui m'ont beaucoup aidé dans ma recherche de stage. ses conseils m'ont permis de cibler mes candidatures, et de trouver ce stage qui était en totale adéquation avec mes attentes.

Je tiens à remercier vivement mon maître de stage, Mr. laurent VUILLON, pour son accueil, le partage de son expertise au quotidien. Grâce aussi à sa confiance j'ai pu m'accomplir totalement dans mes missions. Il fut d'une aide précieuse dans les moments les plus délicats, et vu que ce stage est un peu spécial c'est lui qui s'occupait aussi de me donner des tâches et de m'accompagner jusqu'à les compléter .

Je remercie également mon tuteur professionnel Mr. Annabel SAISSI et son collègue Youva LABATA pour leur accueil, leur esprit d'équipe et en particulier Mr SAISSI le directeur général de l'entreprise qui m'a donné l'opportunité d'appliquer et de développer ce que j'ai appris. Enfin, je tiens à remercier toutes les personnes qui m'ont conseillé et relu lors de la rédaction de ce rapport de stage.

# Table des matières

**1 SELECT ASSUR 66** **3**
1.1 SELECT ASSUR 66 et ses missions . . . . . 3
1.2 Traitement et Analyse de données (Data Analysis) . . . . . 5
1.2.1 Data : qu'est-ce que l'analyse de données ? . . . . . 5
1.2.2 Les missions du Data Analyst . . . . . 5

**2 Arbre de décision et Forêt aléatoire** **7**
2.1 Données des clients . . . . . 7
2.2 Arbre de décision . . . . . 7
2.2.1 Définition et Principe . . . . . 7
2.2.2 Comment est entraîné un arbre de décision . . . . . 9
2.2.3 Le process complet de construction de l'arbre de décision . . . . . 9
2.2.4 Application sur nos données . . . . . 10
2.3 Forêt aléatoire . . . . . 14
2.3.1 La forêt Aléatoire : Principe et motivation . . . . . 14
2.3.2 La procédure de prédiction avec la forêt de décision . . . . . 14
2.3.3 Application sur nos données . . . . . 15

**3 Les conséquences de ce stage** **17**
3.1 Avantages et Inconvénients . . . . . 17
3.2 impact de votre stage sur la construction de mon projet d'études et mon projet professionnel . . . . . 17

# Chapitre 1

# SELECT ASSUR 66

Ma formation Modélisation Mathématique et Analyse Appliquée me permet d'intégrer le marché de travail par plusieurs secteurs d'activités notamment le conseil (sociétés de consulting), la logistique et gestion de production (grandes entreprises de transport), la finance (banques, compagnies d'assurance), santé (pharmacies, laboratoires...) et environnement etc.

Et si on lit le programme de notre formation, on constate que parmi les métiers les plus intéressants qu'on puisse faire grâce le bagage et les compétences techniques à avoir à la fin de ce master, il y a la data analyse, d'ailleurs c'est le métier que j'aime et je compte faire une carrière là-dessus.

Nous pouvons trouver le data-analyst dans tous les secteurs ; n'importe qu'elle entreprise a des données de grand volume et des questions à propos de ces données (nous allons détailler cela dans 1-2) mais nous le trouvons souvent dans les sociétés bancaires et d'assurance c'est pour cela j'ai concentré ma recherche sur ce type d'entreprise et j'ai trouvé l'agence de courtage en assurance SELECT ASSUR 66.

## 1.1 SELECT ASSUR 66 et ses missions

SELECT ASSUR 66 est un cabinet de courtage en assurance, société par actions simplifiée, immatriculée sous le SIREN 819542945, est active depuis 6 ans. Localisée à PERPIGNAN (66000), elle est spécialisée dans le secteur des activités des agents et courtiers d'assurances. Actuellement, il y a deux fonctionnaires dans l'entreprise plus moi ; Annabel SAISSI est président de cette société et Youva LABATA son auxiliaire. Les deux font les mêmes tâches sauf que le directeur n'est pas toujours sur place car il a des autres projets. Ils prennent les informations de client et ils discutent avec lui afin de trouver le contrat d'assurance qui convient le mieux à ses besoins parmi les différentes compagnies d'assurance du marché. ils sont indépendants des assureurs et leur rôle en premier est le conseil. Donc, on peut dire que la mission de l'entreprise, en tant que représentant de l'assuré (là où l'argent représentant de la compagnie), est de fournir à l'assuré les contrats les plus adaptés à sa demande, sur des critères variés comme le type de contrat (assurance de biens ou assurance de personnes, contrats spécifiques...), le rapport garantie-prix, et d'autres critères divers.

Et après c'est eux qui s'occupent de communiquer avec la compagnie d'assurance si l'assuré a un problème ou l'inverse.

## 1.2 Traitement et Analyse de données (Data Analysis)

Les entreprises disposent désormais de volumes de données très importants (big data). Mais pour en faire un usage avisé, elles ont besoin de spécialistes capables de donner du sens au Big Data. Le Data Analyst est un expert capable de faire parler les données (data), et d'en tirer des réponses aux problématiques rencontrées par les entreprises.

### 1.2.1 Data : qu'est-ce que l'analyse de données ?

La Data Analysis (analyse de données) consiste à nettoyer, transformer et modéliser la data pour la traduire en information utile à la prise de décision en entreprise.

En effet, les entreprises reçoivent une immense quantité de données (ou data). Mais ces données informatiques ne sont souvent que de la matière brute. Il faut les mettre en forme et les analyser pour y trouver du sens. C'est c'est le rôle du Data Analyst.

Sa tâche principale consiste à traiter les données disponibles dans les systèmes d'information pour y trouver des indications exploitables par les décideurs, qui les aideront dans la gestion de leur entreprise.

Ces données peuvent concerner les prospects, les clients, les produits ou encore les processus de l'entreprise. Les indications fournies par l'analyste de données pourront par exemple servir à améliorer l'expérience utilisateur d'un site web, à créer des offres qui répondent parfaitement aux besoins des clients en matière de marketing ou encore à optimiser des processus de production.

### 1.2.2 Les missions du Data Analyst

Les missions de l'analyste de données se déclinent autour de 3 grands axes :

— Recueillir les données (data)
— Traduire et interpréter la data
— Rendre compte de ses résultats

#### Recueillir les données

L'objectif du Data Analyst consiste à valoriser la masse de données collectées par l'entreprise.

En premier lieu, face à une problématique donnée, il doit comprendre quelles sont les données (data) à rechercher, puis quel type d'analyse et de définition il devra leur appliquer pour en tirer des enseignements utiles.

Si l'entreprise ne dispose pas d'un profil de Data Engineer, le Data Analyst peut aussi être chargé de créer et modéliser les bases de données de l'entreprise et de veiller à leur bon fonctionnement. Il devra alors recourir à des méthodes d'extraction de données (data) dans un cadre digital.

Ensuite, avant de se lancer dans l'analyse à proprement dite, il lui faut sélectionner soigneusement les sources de données à exploiter. Cependant, les données brutes qu'il récoltera ne seront pas toujours exploitables pour l'analyse. Avant de les analyser, le parcours

du Data Analyst sera d'abord de nettoyer les données, de les traiter et puis de les organiser. Il élabore des critères de segmentation des données pour une exploitation optimale.

### Analyser et interpréter les données

Une fois qu'il a collecté, nettoyé et traité la data, l'analyse et le travail de définition peuvent commencer.

À ce stade, la mission de l'analyste consiste à mettre en place des systèmes d'analyse pour générer de l'information pertinente sur la base des données collectées. En amont, cela exige que l'analyste dispose d'une forte connaissance business (marketing, management, gestion ...) pour faire le lien entre les données informatiques et les enjeux de l'entreprise.

Durant cette phase, le Data Analyst utilise des outils analytiques pour comprendre et interpréter les données. Ensuite, il va produire des rapports pour communiquer ses résultats aux parties prenantes concernées.

La Data Analysis consiste à répondre à des questions dans le but de prendre des décisions plus éclairées. En pratique, l'analyste répond à quatre grands types de questions qui correspondent à quatre grandes catégories d'analyse :

- L'analyse descriptive : répond à la question « que s'est-il passé ? »
- L'analyse diagnostique : donne des réponses à la question « pourquoi cet événement a-t-il eu lieu ? »
- L'analyse prédictive : cherche à prévoir ce qui est susceptible de se produire
- L'analyse prescriptive : répond à l'interrogation « quelle action devrait-on mettre en place ? »

Pour produire un rapport utile, l'analyste doit être capable de détecter des schémas récurrents dans la data. La donnée informatique va alors lui permettre d'identifier des tendances et des indications qui auront une réelle valeur pour l'entreprise.

### Produire et diffuser ses rapports d'analyse sur la data

La troisième mission du Data Analyst consiste à communiquer ses résultats aux personnes concernées. Pour cela, il utilise des outils de data visualization afin de fournir des rapports clairs et intelligibles, y compris pour des personnes non-spécialistes de la data.

Pour détecter des schémas et produire de l'information utile, l'analyste doit produire ces rapports sur une base régulière.

# Chapitre 2

# Arbre de décision et Forêt aléatoire

## 2.1 Données des clients

Comme nous avons indiqué avant, les gens viennent à l'agence pour faire un 'devis', et grâce à les réponses de ces gens nous avons créé une base de données sous forme d'un tableau Excel de huit colonnes (Age, Revenu mensuel en euro, Cotisation annuelle en euros, Durée Contrat par jour, Type d'Assurance, Profession, Situation Familiale, Client ou pas), la dernière colonne 'Client ou pas' indique si la personne en question devient un client ou pas après le devis. Nous avons évité bien sûr des informations inutiles comme le nom, le prénom et le numéro de la carte vitale etc. Et pour commencer notre analyse nous avons importé d'abord le fichier Excel sur Python à l'aide du code suivant :

```
import pandas as pd
donnees = pd.read_excel("C:/Users/HP/Desktop/AssuranceData.xlsx")
donnees.head()
```

Et pour vérifier si les données sont importées, nous affichons les cinq premières lignes du tableau :

| | Age | Revenu mensuel en euro | Cotisation annuelle en euros | Duree Contrat par jour | Type d Assurance | Profession | Situation Familiale | Client ou pas |
|---|---|---|---|---|---|---|---|---|
| 0 | 44 | 2500 | 648.0 | 365 | auto | Salarié | Marié | Oui |
| 1 | 30 | 2100 | 1330.8 | 365 | auto | Salarié | Marié | Oui |
| 2 | 78 | 1500 | 441.6 | 365 | auto | Retraité | Marié | Oui |
| 3 | 30 | 2000 | 60.0 | 15 | auto_temporaire | Salarié | Célibataire | Non |
| 4 | 45 | 3000 | 1332.0 | 365 | mutuelle | Cadre | Marié | Oui |

## 2.2 Arbre de décision

### 2.2.1 Définition et Principe

Un arbre de décision est un outil d'aide à la décision représentant un ensemble de choix sous la forme graphique d'un arbre. Les différentes décisions possibles sont situées

aux extrémités des branches (les « feuilles » de l'arbre), et sont atteintes en fonction de décisions prises à chaque étape. L'arbre de décision est un outil utilisé dans des domaines variés tels que la sécurité, la fouille de données, la médecine, etc. Il a l'avantage d'être lisible et rapide à exécuter. Il s'agit de plus d'une représentation calculable automatiquement par des algorithmes d'apprentissage supervisé.

Les arbres de décision sont utilisés dans des domaines d'aide à la décision (par exemple l'informatique décisionnelle) ou l'exploration de données. Ils décrivent comment répartir une population d'individus (clients d'une entreprise, utilisateurs d'un réseau social, ...) en groupes homogènes selon un ensemble de variables discriminantes (âge, temps passé sur un site Web, catégorie socio-professionnelle, ...) et en fonction d'un objectif fixé (aussi appelé « variable d'intérêt » ou « variable de sortie » ; par exemple : chiffre d'affaires, probabilité de cliquer sur une publicité, ...). Par exemple, supposons qu'aujourd'hui, vous vouliez aller pique-niquer avec votre compagne et vos enfants. Tout d'abord vous allé vérifier qu'il fait beau, par la suite vous allé demander à votre compagne si ça lui-di de pique-niquer si oui, vous allez demander à vos enfants si eux aussi ils sont OK pour pique-niquer et si c'est le cas, vous piquerez avec votre compagne ou compagnon. L'arbre de décision correspondant aux concepts que j'ai énoncé précédemment est le suivant :

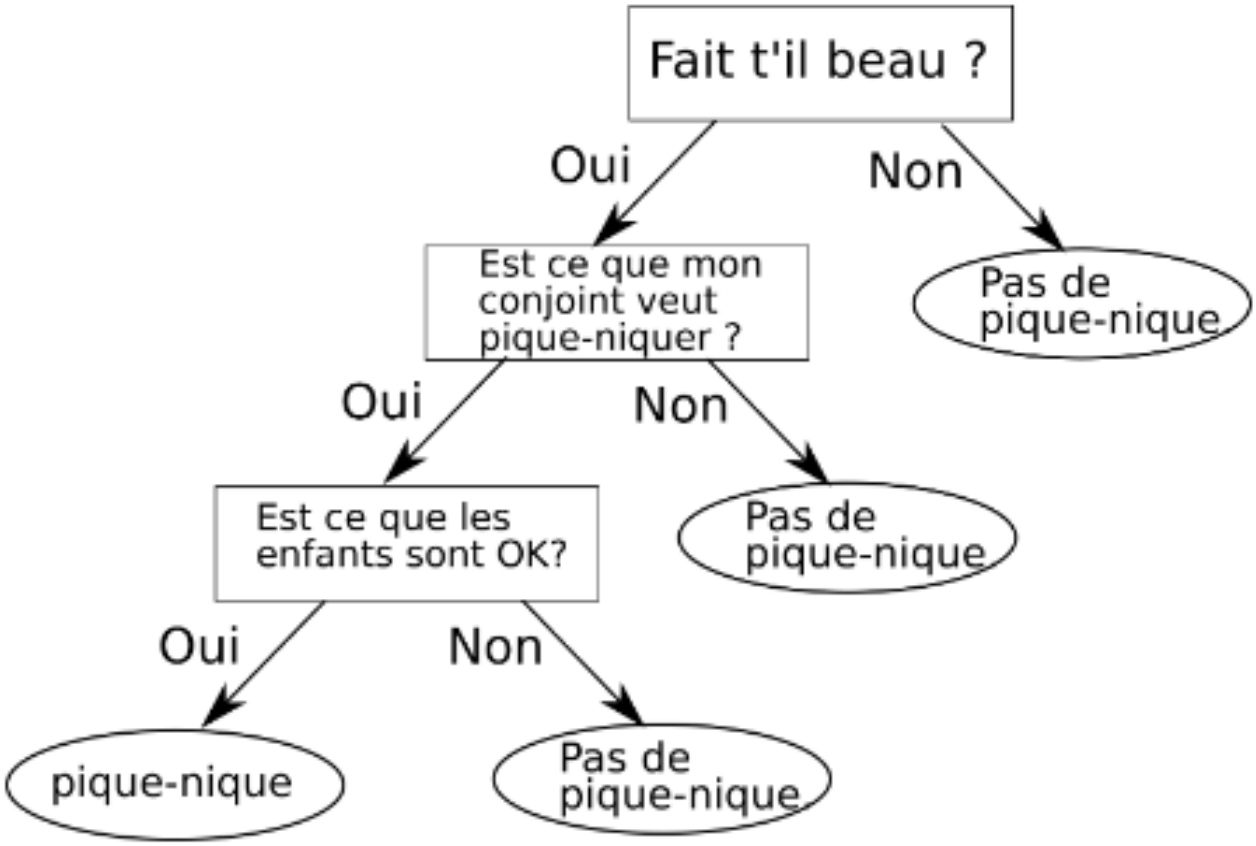

### 2.2.2 Comment est entraîné un arbre de décision

Un arbre de décision est entraîné à la gloutonne si tu me le permets !

Deux cas sont possibles le cas de la classification et le cas de la régression, mais dans les deux cas la manière d'entraîner reste la même, seule change la mesure qui permet de mesurer la qualité des nouvelles branches créées.

Mais dans un premier temps, je vais voir avec toi le cas de la classification, car je t'avoue que c'est probablement plus simple pour la suite de voir ce cas-là, (nous avons traité le cas de la régression dans le paragraphe "Méthode de scoring pour la régression").

Pour la classification, à chacune de ces itérations, l'algorithme d'entraînement va rajouter la décision qu'il lui semble le mieux de rajouter. Pour ce faire, il va tester et évaluer la qualité de toutes les nouvelles décisions qu'il est possible d'ajouter à l'arbre en calculant le score Gini. Le score Gini est un score qui a été spécialement inventé afin de réaliser la sélection des nouvelles branches dans un arbre de décision.

#### Le score Gini

Le score "Gini", est compris entre zéro et 1. Il s'agit d'une valeur numérique indiquant la probabilité que l' arbre se trompe lors de la prise d'une décision ( par exemple qu'il choisit la classe "A" alors que la vraie classe c'est "B").

Il est utilisé quasi systématiquement (dans les bibliothèques populaires de machines learning tel que sklearn) utilisé pour estimer la qualité d'une branche.

Une branche sera rajoutée à l'arbre si parmi toutes les branches qu'il est possible de créer cette dernière présente le score Gini maximal.

Il est possible d'obtenir le score Gini, grâce à la formule suivante :

$$Gini = \sum(pk(1 - pk))$$

ou pk est la probabilité d'obtenir la classe k.

Si l'on reprend l'exemple du pique-nique présenté ci-dessus, le score "Gini" vaudra :

P-pique-nique x (1 - P-pique-nique) + P-non-pique-nique x (1 - Pnon-pique-nique)

### 2.2.3 Le process complet de construction de l'arbre de décision

Pour récapituler, voici le process complet de construction d'un arbre de décision. Il est à noter qu'au début, il est vide. Et que le premier split qui est effectué est ce qui permet de créer la racine. Elle est calculée en choisissant la branche qui admet le score Gini Maximal.

1. À l'initialisation, l'arbre est totalement vide.
2. Le score de toutes les décisions qu'il est possible de prendre est calculé.
3. La décision qui présente le score Gini maximal est choisie comme racine
4. Tant qu'il est possible de faire un split et que le critère d'arrêt n'est pas respecté
5. Pour chaque décision qu'il est possible d'ajouter à l'arbre ; Faire 6.
6. Calcul du score Gini de la décision courante

7. Sélection de la décision admettant le score max et ajout de celle-ci à l'arbre

Il existe de nombreuses conditions d'arrêt possible pour cet algorithme d'entraînement, mais les plus populaires sont les suivantes :

La "maximum tree depth" qui signifie profondeur maximale de l'arbre, il s'agit d'arrêter le développement de l'arbre une fois qu'il a atteint une certaine profondeur, cela évitera que l'arbre construise des branches avec trop peu d'exemples et donc permettra d'éviter un sur apprentissage.

Le "minimum sample split" ou encore nombre d'exemples minimum pour un split consiste à ne pas splitter une branche si la décision concerne trop peu d'exemples. Cela permet également d'empêcher le surapprentissage.

Pour finir, il est également possible de ne pas choisir de critère d'arrêt et de laisser l'arbre se développer jusqu'au bout. Dans ce cas il s'arrêtera que quand il n'y aura plus de split possible. Généralement, quand il n'y a pas de critère d'arrêt, il n'est pas rare qu'un élagage de l'arbre ,ou "pruning" en anglais s'en suive. Élagage consistant à éliminer tous les splits n'améliorant pas le score.

**Méthode de scoring pour la régression**

Pour la régression c'est généralement l'erreur quadratique moyenne ou mean squarred error qui est employée.

Son calcul est simple, c'est la moyenne de toutes les erreurs commises par l'arbre il s'agit de la moyenne de la valeur absolue de la différence constatée entre la prédiction et la vraie valeur.

$MSE = \sum((y_prdit - y_vrai)^2)/nombre_de_prdictions$

### 2.2.4 Application sur nos données

Dans notre exemple nous allons essayer de créer un arbre de décision pour prédire si une personne va devenir un client ou pas en basant sur ses informations : âge, revenu mensuel en euro, cotisation annuelle en euros, durée Contrat souhaité par jour, type d'Assurance, profession, situation familiale. Pour cefaire en python, il te faudra faire appel à la bibliothèque scikit-learn. On commence!!!

**Importation des modules nécessaires :**

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.tree import DecisionTreeClassifier, plot_tree
```

La bibliothèque pandas, on l'a déjà utilisé pour importer les données sur Python, numpy sert à manipuler des tableaux multi-dimensionnels, cette bibliothèque est intéressante car elle contient des fonctions prédéfinies utiles, matplotlib.pyplot est la bibliothèque qui s'occupe

de tracer les graphes et les arbres etc, et enfin il y a sklearn.tree qui nous fait créer et tracer l'arbre de décision. L'étape qui suit l'implémentation des bibliothèques nécessaires dans le code est l'implémentation de données, la chose qu'on a fait dans le paragraphe "données des clients".

**La préparation de données :**

Parmi les problèmes que j'ai rencontré dans ce stage ; la méthode DecisionTreeClassifier n'admet que des tableaux avec des valeurs numériques alors que notre base de données contient des colonnes avec des valeurs non numériques. Alors pour régler ce problème j'ai extrait les colonnes concernés (avec des valeurs non numériques) et j'ai remplacé les chaînes de caractères par des valeurs Binaires, par exemples on remplace les valeurs salarié, retraité, étudiant par les valeurs [1,0,0], [0,1,0], [0,0,1].

```
########## Extraire les attributs avec des valeurs non numériques :
Type_Dassurance=donnees.values[:,4]
Job=donnees.values[:,5]
Situation_Familiale=donnees.values[:,6]
#print (type(Type_Dassurance))
#print(Type_Dassurance)
```

```
########## Encodage entier des données non numériques :
from sklearn.preprocessing import LabelEncoder
label_encoderonehot_Type_Dassurance = LabelEncoder()
integer_encoded_Type_Dassurance = label_encoderonehot_Type_Dassurance.fit_transform(Type_Dassurance)
integer_encoded_Type_Dassurance = integer_encoded_Type_Dassurance.reshape(len(integer_encoded_Type_Dassurance), 1)
#print(integer_encoded_Type_Dassurance)
label_encoder_Job = LabelEncoder()
integer_encoded_Job = label_encoder_Job.fit_transform(Job)
integer_encoded_Job = integer_encoded_Job.reshape(len(integer_encoded_Job), 1)
#print(integer_encoded_Job)
label_encoder_Situation_Familiale = LabelEncoder()
integer_encoded_Situation_Familiale = label_encoder_Situation_Familiale.fit_transform(Situation_Familiale)
integer_encoded_Situation_Familiale=integer_encoded_Situation_Familiale.reshape(
    len(integer_encoded_Situation_Familiale),1)
#print(integer_encoded_Situation_Familiale)
```

```
########## # Ecodage Binaire :
from sklearn.preprocessing import OneHotEncoder
onehot_encoder_Type_Dassurance = OneHotEncoder(sparse=False)
#integer_encoded_Type_Dassurance = integer_encoded_Type_Dassurance.reshape(len(integer_encoded_Type_Dassurance), 1)
onehot_encoded_Type_Dassurance = onehot_encoder_Type_Dassurance.fit_transform(integer_encoded_Type_Dassurance)
#print(onehot_encoded_Type_Dassurance)
onehot_encoder_Job = OneHotEncoder(sparse=False)
#integer_encoded_Job = integer_encoded_Job.reshape(len(integer_encoded_Job), 1)
onehot_encoded_Job = onehot_encoder_Job.fit_transform(integer_encoded_Job)
#print(onehot_encoded_Job)
onehot_encoder_Situation_Familiale = OneHotEncoder(sparse=False)
#integer_encoded_Situation_Familiale = integer_encoded_Situation_Familiale.reshape(len(integer_encoded_Situation_Fam
onehot_encoded_Situation_Familiale = onehot_encoder_Situation_Familiale.fit_transform(
    integer_encoded_Situation_Familiale)
#print(onehot_encoded_Situation_Familiale)
```

Ensuite, on concatène les données qu'on a transmet avec les données numériques de notre base de données pour avoir cette fois-ci un tableau qu'avec des données numériques.

```
########## Reconstruire le tableau de données qu'avec des features numériques :
donneesCible=donnees.values[:,-1].reshape(len(donnees.values[:,-1]),1)
donnees0=np.hstack((
    onehot_encoded_Type_Dassurance,onehot_encoded_Job,onehot_encoded_Situation_Familiale,donneesCible))
donnees1=np.hstack((donnees.values[:,0:4],donnees0))


features_classes=donnees1[:,0:7]
Cible_classe=donnees1[:,-1]
#features_classes[0:3]
#Cible_classe[0:15]
```

**Création et affichage de notre arbre de décision :**

Après, on arrive à l'étape la plus importante, c'est la création de notre modèle et l'affichage de l'arbre à l'aide des méthodes suivantes : DecisionTreeClassifier, Notre-modele.fit et plot-tree. Il est à noter qu'on a utilisé la méthode DecisionTreeClassifier car la variable à prédire est une variable qualitative, si la variable à prédire est quantitative on importe DecisionTreeRegressor au lieu de DecisionTreeClassifier.

```
##### creation de modèle de créduction
#Déclaration de l'arbre de décision
Notre_modele = DecisionTreeClassifier(criterion="gini",max_depth=7)
Notre_modele.fit(features_classes,Cible_classe)
#Affichage de l'abre de décision obtenu après entraînement plus grand pour une meilleure lisibilité
import matplotlib.pyplot as plt
plt.figure(figsize=(40,40))
plot_tree(Notre_modele,feature_names= ['Age','Revenu mensuel en euro','Cotisation annuelle en euros',
                                       'Duree Contrat par jour','Type d Assurance','Profession',
                                       'Situation Familiale'],
          class_names=["Oui","Non"],filled=True)
plt.show()
```

Enfin, lorsqu'on a exécuté le script le résultat était comme suit :

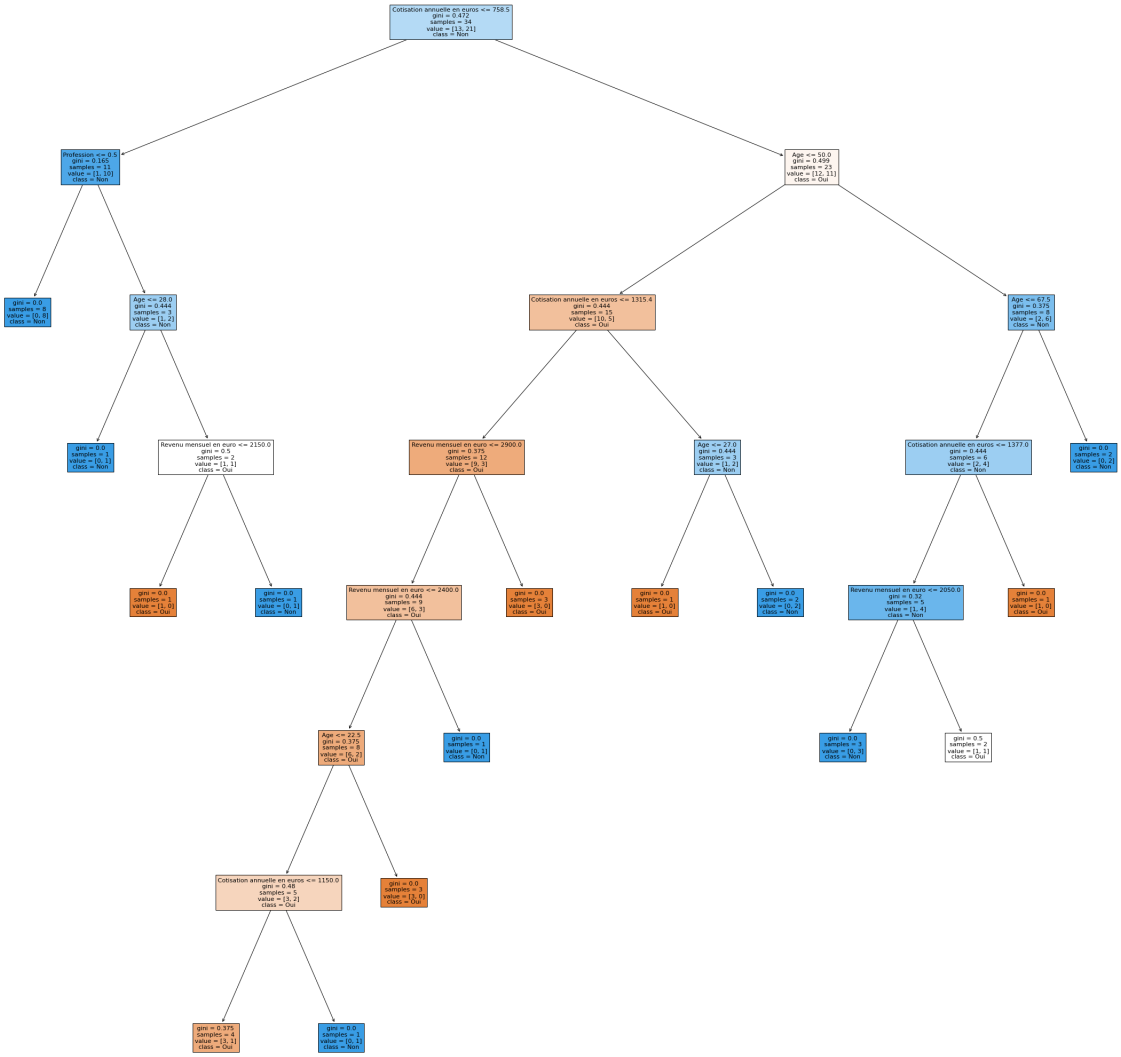


**Validation du modèle et prédictions :**

Une fois notre modèle appris, il faut le valider(c'est-à-dire, il faut calculer Le pourcentage de bien classés ; généralement si ce pourcentage dépasse 70 % on valide le modèle et on l'utilise). Pour cela, on va utiliser les données de test et des indicateurs très classiques.

On compare donc la valeur prédite par le modèle avec la valeur dans les données. Il s'agit ici de comparer la valeur de la variable "Client ou pas" prédite par le modèle et celle observée dans notre échantillon test.

Le premier indicateur utilisé est le pourcentage de bien classé aussi appelé accuracy :

```
#Test
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test  = train_test_split(features_classes,
                                                     Cible_classe,test_size=0.25,
                                                     random_state=42)

from sklearn.metrics import accuracy_score, confusion_matrix
print(f"Le pourcentage de bien classés est de : {accuracy_score(y_test,
Notre_modele.predict(x_test))*100} %")
```

Le pourcentage de bien classés est de : 88.88888888888889 %, alors on valide le modèle.

## 2.3 Forêt aléatoire

Comme son nom l'indique, cette méthode est basée sur la notion de forêt et que ce soit en data science ou dans la réalité, une forêt est constitué des mêmes éléments : des arbres. Avant de comprendre la notion de forêt aléatoire, il faut donc comprendre la notion d'arbre.

### 2.3.1 La forêt Aléatoire : Principe et motivation

**Pourquoi alors la forêt aléatoire si l'arbre de décision marche bien et a un pourcentage de bien classés élevé ?**

Un arbre possède de nombreux avantages, notamment une interprétabilité extrêmement grande. Néanmoins, il possède une très grande faiblesse, sa stabilité. En effet, un arbre est extrêmement sensible à de petits changements dans les données d'apprentissage. Si vous changez légèrement les données, l'arbre peut en être totalement modifié. Afin de contrer cette faiblesse, les forêts aléatoires ont été créées.

**Le principe de la forêt aléatoire**

Le principe de la forêt aléatoire est simple, il s'agit de multiplier les arbres. Mais bien évidemment, si vous créez 100 arbres sur les mêmes données, vous allez obtenir 100 fois le même arbre. Nous allons donc modifier légèrement les données pour chacun des 100 arbres.

### 2.3.2 La procédure de prédiction avec la forêt de décision

**Le rééchantillonnage par bootstrap**

Afin de modifier légèrement les données, nous allons utiliser une méthode bien connue des statisticiens : le bootstrap. Il s'agit d'une méthode qui permet, à partir d'un échantillon, de construire de nouveaux échantillons par tirage aléatoire avec remise. Ceci revient à faire pour le cas d'un jeu de données avec par exemple dans nos données 34 lignes et 8 colonnes :

1. On a un échantillon original de 34 lignes et 8 colonnes.

2. On tire aléatoirement avec remise 34 lignes (ceci veut dire qu'on aura 34 lignes dans le nouvel échantillon mais avec certaines lignes de l'échantillon original plusieurs fois et d'autres pas du tout).
3. On répète l'étape 2 autant de fois qu'on a besoin d'arbres dans la forêt (disons 100 fois).

**L'apprentissage de la forêt**

Une fois les échantillons générés, on peut construire les arbres. Pour cela, on va tirer aléatoirement certaines colonnes de nos données de façon à ne pas utiliser toutes les colonnes simultanément et apprendre sur chaque échantillon bootstrap. On aura donc 100 arbres qui seront tous légèrement différents.

Une fois l'apprentissage terminé, les règles de décisions des 100 arbres sont stockées afin d'être appliquées en mode prédictif. Ceci revient à faire passer une nouvelle observation dans les 100 arbres et chaque arbre va définir une classe d'appartenance, un vote de majorité est appliqué pour établir la classe prédite.

### 2.3.3 Application sur nos données

La récupération et la préparation de données , l'implémentation de bibliothèques nécessaires se font de la même façon sauf là on va utiliser RandomForestClassifier de la bibliothèque sklearn.ensemble. La requête qui créer la forêt aléatoire est : modele_rf = RandomForestClassifier( n_estimators=100, criterion='gini', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='auto', max_leaf_nodes=None, min_impurity_decrease=0.0, bootstrap=True, oob_score=False, n_jobs=None, random_state=None, verbose=0, warm_start=False, class_weight=None, ccp_alpha=0.0, max_samples=None,)

Tous ces hyperparamètres ont des valeurs par défaut que nous modifions rarement, mais il est utile de les comprendre. En voici un description rapide :

— n_estimators : il s'agit du nombre d'arbres dans la forêt
— criterion : il s'agit du critère utilisé pour construire les arbres et séparer les branches des arbres
— max_depth : il s'agit de la profondeur maximale des arbres utilisés (le nombre de niveaux dans l'arbre de décision)
— min_sample_split : il s'agit du nombre d'échantillons minimal dans une feuille pour refaire une séparation
— min_samples_leaf : il s'agit du nombre d'échantillons minimal pour créer une feuille
— min_weight_fraction_leaf : il s'agit de la fraction du nombre total d'échantillon minimal pour créer une feuille
— max_features : il s'agit du nombre de colonnes sélectionnées pour chaque arbre (par défaut on prend la racine carré du nombre de colonnes)
— max_leaf_nodes : il s'agit du nombre maximal de feuilles
— min_impurity_decrease : il s'agit de la baisse minimale du critère d'impureté pour faire une séparation

— bootstrap : paramètre pour utiliser du bootstrap, si il est à False, le même échantillon est pris pour chaque arbre
— n_jobs ; nombre de traitements à effectuer en parallèle
— random_state : graine aléatoire
— warm_start : ceci permet de repartir du résultat du dernier apprentissage pour faire l'apprentissage
— class_weights : il s'agit des poids associés à chaque classe si cela a un sens
— max_samples : si vous voulez réduire le nombre d'observations dans vos échantillons bootstrap

$Bienentendu, vousnetoucherezquasimentaucundeceshyperparamtresmaisilsvouspermettentnanmoin$

Nous avons donc construit un objet forêt aléatoire, nous devons maintenant effectuer l'apprentissage :

```
modele_rf.fit(x_train, y_train)
```

On peut afficher l'importance des variables de notre modèle de forêt aléatoire :

```
# L'importance des variables de notre modèle :
pd.DataFrame(modele_rf.feature_importances_,index =['Age', 'Revenu mensuel en euro'
                                                    , 'Cotisation annuelle en euros',
                                                    'Duree Contrat par jour'
                                                    , 'Type d Assurance',
                                                    'Profession','Situation Familiale'],
             columns =
             ["importance"]).sort_values("importance", ascending = False)
```

| | importance |
|---|---|
| Age | 0.286948 |
| Cotisation annuelle en euros | 0.265240 |
| Duree Contrat par jour | 0.166691 |
| Revenu mensuel en euro | 0.151228 |
| Situation Familiale | 0.059015 |
| Type d Assurance | 0.049185 |
| Profession | 0.021693 |

On voit que la variable la plus importante (au sens de son importance dans les arbres générés) est total l'âge. On voit que la moins importante est la profession.

# Chapitre 3

# Les conséquences de ce stage

## 3.1 Avantages et Inconvénients

Durant la période que j'ai passé là comme stagiaire j'ai bénéficié de beaucoup d'avantages notamment :

- Découvrir le monde de l'entreprise : c'était pour moi l'occasion de découvrir pour la première fois le monde professionnel, de comprendre comment fonctionne réellement une entreprise, d'apprendre à m'intégrer dans une équipe, de développer mon savoir-être, etc.
- affiner mon projet professionnel : ce stage m'a permis de confirmer mes intentions initiales de travailler en traitement et analyse de données.
- Développer mon réseau : il est claire que efectuer un stage en entreprise, c'est également l'occasion de créer un réseau professionnel. Mon objectif est de laisser une bonne image de moi pour garder contact qui peut m'aider après.
- Apprendre mon futur métier auprès de professionnel aguerri : c'est vrai que mon tuteur à l'entreprise ne m'a pas beaucoup aider techniquement mais par contre mon tuteur à l'université m'a beaucoup rapprocher au métier.
- C'est la première fois que j'utilise Latex pour rédiger un document, donc j'ai appris beaucoup de choses là-dessus.

Mais il y a des inconvénients aussi comme :

- le volume de données que je traite : il n'y a pas beaucoup de données car c'est une petite entreprise.
- la durée de stage permit de découvrir le domaine et faire le premier pas mais ne suffit pas à prendre assez de chose.

## 3.2 impact de votre stage sur la construction de mon projet d'études et mon projet professionnel

Comme vous le savez, notre formation, que j'ai choisi par goût, nous donne l'opportunité de faire le premier pas dans de nombreux métiers, et parmi ces métiers il y a celui que j'ai

aimé, c'est le traitement et l'analyse de données car on a un programme riche en éléments qui facilitent les tâches et le travail d'un analyste de données, donc bien évidemment ce que je fais en stage m'aidera beaucoup l'année prochaine dans mon master et donc réaliser mon projet d'étude qui est obtenir ce master. En ce qui concerne mon projet professionnel, personnellement je considère que ce stage est mon premier pas dans le domaine, j'ai découvert le monde de l'entreprise, j'ai réalisé des tâches, je savais comment chercher et où, donc le stage de 6 mois u l'alternance de l'année prochaine sera moins difficile et ça va renforcer mon savoir-faire, comme ça je serai prêt à chercher un CDI comme Data Analyst.

# Réferences

[1] https ://kongakura.fr/article/arbre-de-decision-python

[2] https ://www.stat4decision.com/fr/foret-aleatoire-avec-python

[3] https ://fr.acervolima.com/implementation-de-l-arbre-de-decision-a-l-aide-de-python/

[4] https ://www.lewagon.com/fr/metiers-tech/data-science/data-analyst

[5] https ://fr.wikipedia.org/wiki/Arbre-de-d